实验要求：

1. 请把实验步骤下所有内容以及实验对比分析和参考文献部分补充完整。介绍数据集的来源以及属性特征的含义；训练集和测试集的划分方式；数据预处理的过程；代码实现给出源代码，运行结果给出运行结果截图并进行分析；实验对比分析，可以用表格汇总三种模型的评价指标，进行对比分析。

2. 报告提交电子版（命名格式：专业+班级+学号+姓名，如：

“机器学习-实验一：软件专硕 221 班 202235xx 张三”

最后提交时，这页内容删除。

大连交通大学

《机器学习》上机实验七

题　　目　利用 PCA 和 SVD 对音乐数据进行降维

学生姓名　　专业班级　软件专硕 221 班

学号　20223561

所在院系

指导教师　殷丽凤

完成日期　2024　年　4　月　23　日

一、实验目的和要求

实验目的：

1. 了解降维作用和意义。
2. 掌握 PCA 降维的工作原理，实现的步骤。
3. 掌握 SVD 降维的工作原理，实现的步骤。
4. 熟悉降维的评价指标：PCA 主要通过方差解释率来衡量降维效果，而 SVD 则通过奇异值来衡量。

实验要求：

1. 阅读相关文献或教材，理解降维在数据处理和机器学习中的作用和意义，包括降低计算成本、减少过拟合风险、提高模型解释性等方面的内容。
2. 学习 PCA 降维的原理，包括特征值分解、协方差矩阵、主成分选择等内容。
3. 学习 SVD 降维的原理，包括奇异值分解、截断奇异值分解等内容。
4. 理解 PCA 主要通过方差解释率来衡量降维效果的原理，以及如何计算和解释方差解释率。
5. 理解 SVD 通过奇异值来衡量降维效果的原理，以及如何根据奇异值的大小选择保留的信息量。
6. 使用 Python 或其他工具计算音乐数据在降维过程中的方差解释率或奇异值，并根据评价指标评估降维效果的好坏。
7. 通过以上实验要求的学习和实践，你将能够全面理解降维的概念、原理和方法，并掌握实现和评价降维算法的技能。
8. 撰写实验报告，包括实验内容和方法、实验步骤、实验对比分析、以及对实验中遇到的问题和解决方法的总结等内容。

二、实验内容与方法

2.1 PCA 算法

2.1.1 PCA 算法的原理

PCA 是运用“降维”思想，把多个指标变换成少数综合指标的多元统计方法，这里的综合指标就是主成分。每个主成分都是原始变量的线性组合，彼此相互独立，并保留了原始变量绝大部分信息。其本质是通过原始变量的相关性，寻求相关变量的综合替代对象，并且保证了转化过程中的信息损失最小。

主成分与原始变量之间的关系：

1）主成分是原始变量的线性组合；

2）主成分的数量相对于原始数量更少；

3）主成分保留了原始变量的大部分信息；

4）主成分之间相互独立；

2.1.2 PCA 算法的步骤

PCA 算法步骤如下：

假设样本数据为 $\boldsymbol{X}$，有 m 个特征，共计 n 个样本。

$$\boldsymbol{X}=\begin{bmatrix} x_{11} & x_{12} & \cdots x_{1m} \\ x_{21} & x_{22} & \cdots x_{2m} \\ \vdots & \vdots & \cdots \vdots \\ x_{n1} & x_{n2} & \cdots x_{nm} \end{bmatrix}$$

1.计算数据 X 的协方差矩阵 $\boldsymbol{XX}^T$

1）计算每一列的平均值 $\mu_i=\frac{1}{n}\sum_{j=1}^{n}x_{ji}$；

2）对数据进行去中心化处理，$z_{ji}=x_{ji}-\mu_i$，得到矩阵 $\boldsymbol{Z}$：

$$\boldsymbol{Z}=\begin{bmatrix} z_{11} & z_{12} & \cdots z_{1m} \\ z_{21} & z_{22} & \cdots z_{2m} \\ \vdots & \vdots & \cdots \vdots \\ z_{n1} & z_{n2} & \cdots z_{nm} \end{bmatrix}$$

3）根据式（9.25）和式（9.26）计算协方差矩阵 $\boldsymbol{\Sigma}$。

2.计算 $\boldsymbol{\Sigma}$ 的特征值及对应特征向量

3.选择主成分个数以及主成分对应的向量矩阵。

协方差矩阵 $\boldsymbol{\Sigma}$ 是实对称阵，其特征值为非负。根据设定的阈值，确定降维数 p。取前 p 个特征值 $\lambda_1\geq\lambda_2\geq\lambda_3\geq\ldots\geq\lambda_p\geq 0$ 对应的特征向量，它们对应的特征向量 $\boldsymbol{w}_i$（$i\in[1,p]$），则

$$\boldsymbol{W}=(\boldsymbol{w}_1,\ \boldsymbol{w}_2,\ \ldots\ \boldsymbol{w}_p)$$

4.对样本集的每一个样本 $\boldsymbol{x}_i$，映射为新的样本 $\boldsymbol{z}_i$：

$$\boldsymbol{z}_i=\boldsymbol{W}^T\boldsymbol{x}_i$$

5.得到映射后的样本集 $\boldsymbol{X}'$：

$$\boldsymbol{X}'=(\boldsymbol{z}_1,\boldsymbol{z}_2,\ldots,\ \boldsymbol{z}_m)$$

2.2 奇异值分解（SVD）

2.2.1 SVD 的定义

SVD 也是对矩阵进行分解，但是和特征分解不同，SVD 并不要求要分解的矩阵为方阵。假设的矩阵 $\boldsymbol{A}$ 是一个 $m\times n$ 的矩阵，那么定义矩阵 $\boldsymbol{A}$ 的 SVD 为

$$\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}_{SVD}\boldsymbol{V}^T \tag{9-31}$$

其中 $\boldsymbol{U}$ 是一个 $m\times m$ 的矩阵，$\boldsymbol{\Sigma}_{SVD}$ 是一个 $m\times n$ 的矩阵，除了主对角线上的元素以外全为 0，主对角线上的每个元素都称为奇异值，$\boldsymbol{V}$ 是一个 $n\times n$ 的矩阵。$\boldsymbol{U}$ 和 $\boldsymbol{V}$ 都是酉矩阵，即满足 $\boldsymbol{U}^T\boldsymbol{U}=\boldsymbol{I}$，$\boldsymbol{V}^T\boldsymbol{V}=\boldsymbol{I}$。图 9-7 可以很形象的看出上面 SVD 的定义。

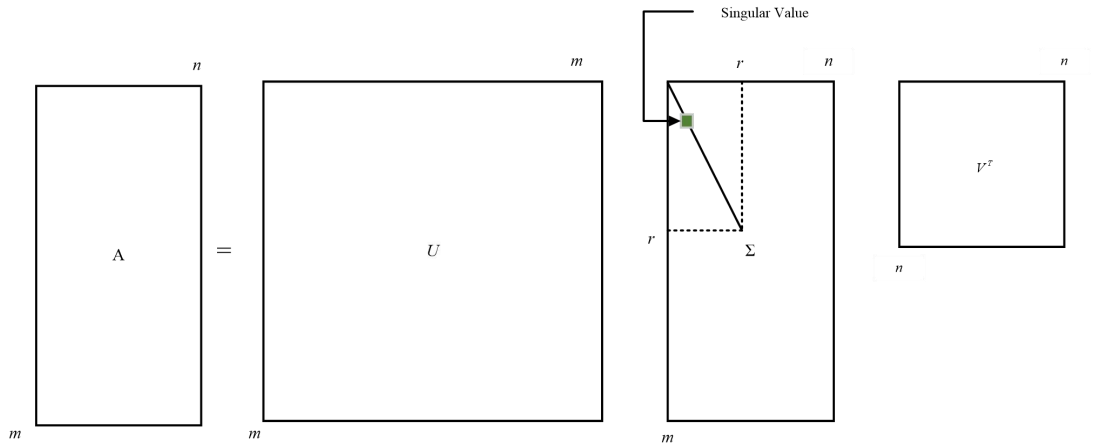

图 9-7 奇异值分解示意图

那么如何求出 SVD 分解后的 $\boldsymbol{U}$，$\boldsymbol{\Sigma}_{SVD}$，$\boldsymbol{V}$ 这三个矩阵呢?

如果将 $\boldsymbol{A}$ 的转置 $\boldsymbol{A}^T$ 和 A 做矩阵乘法，那么会得到 $n\times n$ 的一个方阵 $\boldsymbol{A}^T\boldsymbol{A}$。既然 $\boldsymbol{A}^T\boldsymbol{A}$ 是方阵，那么就可以进行特征分解，得到的特征值和特征向量且满足式（9-32）。

$$(\boldsymbol{A}^T\boldsymbol{A})\boldsymbol{v}_i=\lambda_i\boldsymbol{v}_i \tag{9-32}$$

这样就可以得到矩阵 $\boldsymbol{A}^T\boldsymbol{A}$ 的 n 个特征值 λ_i 和对应的 n 个特征向量 $\boldsymbol{v}_i$ 了。将 $\boldsymbol{A}^T\boldsymbol{A}$ 的所有特征向量张成一个 $n\times n$ 的矩阵 $\boldsymbol{V}$，就是 SVD 公式里面的 $\boldsymbol{V}$ 矩阵了。一般将 $\boldsymbol{V}$ 中的每个特征向量叫做 $\boldsymbol{A}$ 的右奇异向量。

如果将 $\boldsymbol{A}$ 和 $\boldsymbol{A}$ 的转置 $\boldsymbol{A}^T$ 做矩阵乘法，那么会得到 $m\times m$ 的一个方阵 $\boldsymbol{A}\boldsymbol{A}^T$。既然 $\boldsymbol{A}\boldsymbol{A}^T$ 是方阵，那么就可以进行特征分解，得到的特征值和特征向量满足式（9-33）。

$$(\boldsymbol{A}\boldsymbol{A}^T)\boldsymbol{u}_i=\lambda_i\boldsymbol{u}_i \tag{9-33}$$

这样就可以得到矩阵 $\boldsymbol{A}\boldsymbol{A}^T$ 的 m 个特征值和对应的 m 个特征向量 $\boldsymbol{u}$ 了。将 $\boldsymbol{A}\boldsymbol{A}^T$ 的所有特征向量张成一个 $m\times m$ 的矩阵 $\boldsymbol{U}$，就是 SVD 公式里面的 $\boldsymbol{U}$ 矩阵了。一般将 $\boldsymbol{U}$ 中的每个特征向量叫做 $\boldsymbol{A}$ 的左奇

异向量。

$\boldsymbol{U}$ 和 $\boldsymbol{V}$ 都求出来了，现在就剩下奇异值矩阵 $\boldsymbol{\Sigma}$ 没有求出了。由于 $\boldsymbol{\Sigma}$ 除了对角线上是奇异值其他位置都是 0，那只需要求出每个奇异值 σ 就可以了。

注意到：$\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}_{SVD}\boldsymbol{V}^T \Rightarrow \boldsymbol{A}\boldsymbol{V}=\boldsymbol{U}\boldsymbol{\Sigma}_{SVD}\boldsymbol{V}^T\boldsymbol{V} \Rightarrow \boldsymbol{A}\boldsymbol{V}=\boldsymbol{U}\boldsymbol{\Sigma}_{SVD} \Rightarrow \boldsymbol{A}\boldsymbol{v}_i=\sigma_i\boldsymbol{u}_i \Rightarrow \sigma_i=\boldsymbol{A}\boldsymbol{v}_i/\boldsymbol{u}_i$，这样可以求出每个奇异值，进而求出奇异值矩阵 $\boldsymbol{\Sigma}$。

为什么说 $\boldsymbol{A}^T\boldsymbol{A}$ 的特征向量组成的矩阵就是 SVD 中的 $\boldsymbol{V}$ 矩阵，而 $\boldsymbol{A}\boldsymbol{A}^T$ 的特征向量组成矩阵就是 SVD 中的 $\boldsymbol{U}$ 矩阵，这有什么根据吗?下面给出以 $\boldsymbol{V}$ 矩阵为例的推导过程。

$$\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}_{SVD}\boldsymbol{V}^T \Rightarrow \boldsymbol{A}^T=\boldsymbol{V}(\boldsymbol{\Sigma}_{SVD})^T\boldsymbol{U}^T \Rightarrow \boldsymbol{A}^T\boldsymbol{A}=\boldsymbol{V}(\boldsymbol{\Sigma}_{SVD})^T\boldsymbol{U}^T\boldsymbol{U}\boldsymbol{\Sigma}_{SVD}\boldsymbol{V}^T=\boldsymbol{V}(\boldsymbol{\Sigma}_{SVD})^2\boldsymbol{V}^T$$

其中 $\boldsymbol{U}^T\boldsymbol{U}=\boldsymbol{I},(\boldsymbol{\Sigma}_{SVD})^T(\boldsymbol{\Sigma}_{SVD})=(\boldsymbol{\Sigma}_{SVD})^2$，所以 $\boldsymbol{A}^T\boldsymbol{A}$ 的特征向量组成的矩阵就是 SVD 中的 $\boldsymbol{V}$ 矩阵。类似的方法可以得到 $\boldsymbol{A}\boldsymbol{A}^T$ 的特征向量组成的矩阵就是 SVD 中的 $\boldsymbol{U}$ 矩阵。

进一步还可以看出特征值矩阵等于奇异值矩阵的平方，也就是说特征值和奇异值满足如下关系:

$$\sigma_i=\sqrt{\lambda_i} \tag{9-34}$$

可以不用 $\sigma_i=\boldsymbol{A}\boldsymbol{v}_i/\boldsymbol{u}_i$ 来计算奇异值，也可以通过求出 $\boldsymbol{A}^T\boldsymbol{A}$ 的特征值取平方根来求奇异值。

2.2.2 SVD 的计算步骤

给定一个 $m\times n$ 的矩阵 $\boldsymbol{A}$，奇异值分解的步骤如下：

1）计算 $\boldsymbol{A}\boldsymbol{A}^T$ 的特征值和特征向量：求得的特征向量矩阵 $\boldsymbol{U}$ 是 $\boldsymbol{A}\boldsymbol{A}^T$ 的特征向量的标准化形式。

2）计算 $\boldsymbol{A}^T\boldsymbol{A}$ 的特征值和特征向量：求得的特征向量矩阵 $\boldsymbol{V}$ 是 $\boldsymbol{A}^T\boldsymbol{A}$ 的特征向量的标准化形式。

3）从 $\boldsymbol{A}\boldsymbol{A}^T$ 的特征值计算奇异值：$\boldsymbol{\Sigma}_{SVD}$ 是一个对角矩阵，对角线上的元素是 $\boldsymbol{A}\boldsymbol{A}^T$ 的特征值的平方根。

4）根据求得的 $\boldsymbol{U}$、$\boldsymbol{V}$、$\boldsymbol{\Sigma}_{SVD}$ 进行奇异值分解：$A=\boldsymbol{U}\boldsymbol{\Sigma}_{SVD}\boldsymbol{V}$。

2.2.3 SVD 的性质

上面几节对 SVD 的定义和计算做了详细的描述，似乎看不出费这么大的力气做 SVD 有什么好处。那么 SVD 有什么重要的性质值得注意呢?

1）对于奇异值，它跟特征分解中的特征值类似，在奇异值矩阵中也是按照从大到小排列，而且奇异值的减少特别的快，在很多情况下，前 10%甚至 1%的奇异值的和就占了全部的奇异值之和的 99%以上的比例。也就是说，也可以用最大的 k 个的奇异值和对应的左右奇异向量来近似描述矩阵。也就是说下面的式（9-35）成立：

$$\boldsymbol{A}_{m\times n}=\boldsymbol{U}_{m\times n}(\boldsymbol{\Sigma}_{SVD})_{n\times n}(\boldsymbol{V}_{n\times n})^T \approx \boldsymbol{U}_{m\times k}(\boldsymbol{\Sigma}_{SVD})_{k\times k}(\boldsymbol{V}_{k\times n})^T \tag{9-35}$$

其中，k 要比 n 小很多，也就是一个大的矩阵 $\boldsymbol{A}$ 可以用三个小的矩阵 $\boldsymbol{U}_{m\times k},\boldsymbol{\Sigma}_{k\times k},(\boldsymbol{V}_{k\times n})^T$ 来表示。

如图 9-8 所示，现在矩阵 $\boldsymbol{A}$ 只需要灰色的部分的三个小矩阵就可以近似描述了。

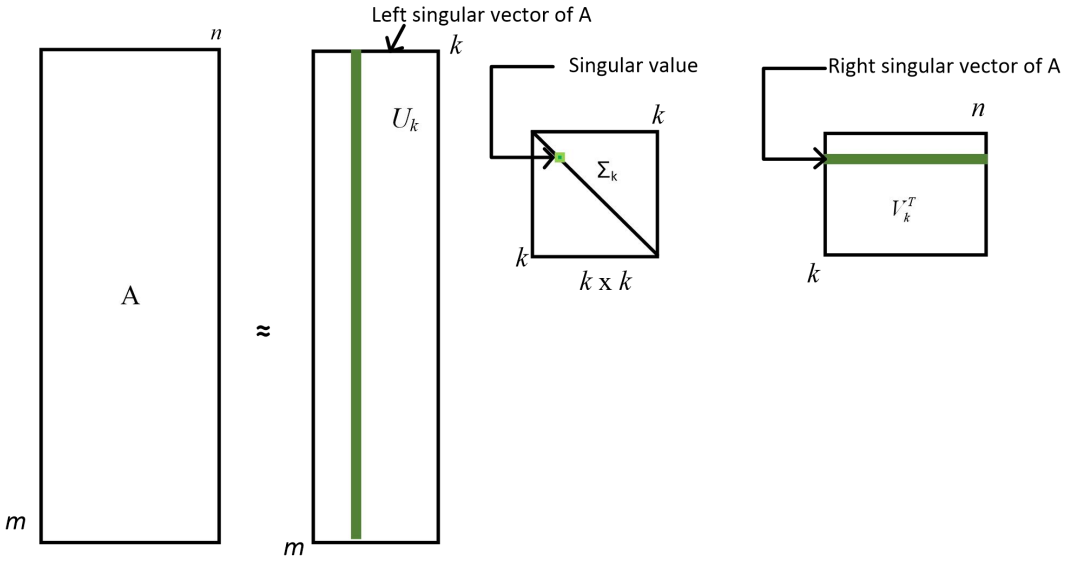

图 9-8 矩阵 **A 的分解示意图**

由于这个重要的性质，SVD 可以用于 PCA 降维，来做数据压缩和去噪。也可以用于推荐算法，将用户和喜好对应的矩阵做特征分解，进而得到隐含的用户需求来做推荐。同时也可以用于 NLP 中的算法，比如潜在语义索引(LSI)。下面介绍一下 SVD 用于 PCA 降维。

2）SVD 用于 PCA

在主成分分析(PCA）原理总结中，要用 PCA 降维，需要找到样本协方差矩阵 $\boldsymbol{XX}^T$ 的最大的 d 个特征向量，然后用这最大的 d 个特征向量张成的矩阵来做低维投影降维。可以看出，在这个过程中需要先求出协方差矩阵 $\boldsymbol{XX}^T$，当样本数多且样本特征数也多的时候，这个计算量是很大的。

注意到：SVD 也可以得到协方差矩阵 $\boldsymbol{XX}^T$ 最大的 d 个特征向量张成的矩阵，但 SVD 有个好处，有一些 SVD 的实现算法可以不求先求出协方差矩阵 $\boldsymbol{XX}^T$，也能求出右奇异矩阵 $\boldsymbol{V}$。也就是说，PCA 算法可以不用做特征分解，而是做 SVD 来完成。这个方法在样本量很大的时候很有效。实际上，scikit-learn 的 PCA 算法的背后真正的实现就是用的 SVD，而不是暴力特征分解。

另一方面，注意到 PCA 仅仅使用了 SVD 的右奇异矩阵，没有使用左奇异矩阵，那么左奇异矩阵有什么用呢?

假设样本是 $m\times n$ 的矩阵 $\boldsymbol{X}$，如果通过 SVD 找到了矩阵 $\boldsymbol{XX}^T$ 最大的 d 个特征向量张成的 $m\times d$ 维矩阵 $\boldsymbol{U}$，则如果进行如下处理：

$$(\boldsymbol{X}')_{d\times n} = (\boldsymbol{U}^T)_{d\times m}\boldsymbol{X}_{m\times n} \tag{9-36}$$

可以得到一个 $d\times n$ 的矩阵 $\boldsymbol{X}'$，这个矩阵和原来的 $m\times n$ 维样本矩阵 $\boldsymbol{X}$ 相比，行数从 m 减到了 d，可见对行数进行了压缩，也就是说，左奇异矩阵可以用于行数的压缩。相对的，右奇异矩阵可以用于列数即特征维度的压缩，也就是 PCA 降维。

SVD 作为一个很基本的算法，在很多机器学习算法中都有它的身影，特别是在现在的大数据时代，由于 SVD 可以实现并行化，因此更是大展身手。SVD 的原理不难，只要有基本的线性代数知

识就可以理解，实现也很简单因此值得仔细的研究。当然，SVD 的缺点是分解出的矩阵解释性往往不强，有点黑盒子的味道，不过这不影响它的使用。

三、实验步骤

3.1 数据集

3.2 数据预处理

3.3 利用 PCA 对音乐数据降维

3.3.1 实现代码

3.3.2 运行结果

3.4 利用 SVD 对音乐数据降维

3.4.1 代码实现

3.4.2 运行结果

四、实验对比分析

五、实验总结

六、参考文献