实验要求：

1. 请把实验步骤下所有内容以及实验对比分析和参考文献部分补充完整。介绍数据集的来源以及属性特征的含义；训练集和测试集的划分方式；数据预处理的过程；代码实现给出源代码，运行结果给出运行结果截图并进行分析；实验对比分析，可以用表格汇总三种模型的评价指标，进行对比分析。

2. 报告提交电子版（命名格式：专业+班级+学号+姓名，如：

“机器学习-实验一：软件专硕 221 班 202235xx 张三”

最后提交时，这页内容删除。

大连交通大学

《机器学习》上机实验二

题　　目　利用神经网络构建癌症分类模型

学生姓名　　专业班级　软件专硕 221 班

学号　20223561

所在院系

指导教师　殷丽凤

完成日期　2024　年　3　月　27　日

一、实验目的和要求

实验目的：

1. 掌握感知机模型和前馈神经网络的工作原理。
2. 掌握梯度下降、随机梯度下降和小批量梯度下降训练方法。
3. 掌握准确率、精准率、召回率、F1 等分类评价指标。
4. 熟悉利用 Python 语言人工实现感知机和多层感知机对癌症进行分类；或熟悉利用 numpy、pandas、matplotlb、scikit-learn 等库实现感知机和多层感知机对癌症进行分类。

实验要求：

1. 深入理解感知机模型和前馈神经网络的工作原理，包括神经元的结构和功能、激活函数的作用、前向传播和反向传播的过程。
2. 理解梯度下降、随机梯度下降和小批量梯度下降等训练方法的原理和区别。
3. 掌握各个评价指标的含义。
4. 实现感知机和多层感知机模型对癌症进行分类的人工实验；或者利用库实现对癌症进行分类的实验；实验中包括数据的预处理、模型的构建、训练和评估。
5. 撰写实验报告，包括实验内容和方法、实验步骤、实验对比分析、以及对实验中遇到的问题和解决方法的总结等内容。

二、实验内容与方法

2.1 神经网络

2.1.1 感知机模型的原理

感知机算法的目标是找到一个超平面，使得所有的训练样本都被正确分类。具体地，对于一个样本$(\boldsymbol{x}_i,y_i)$，如果它被错误分类了，那么就需要更新超平面的参数，使得它能够正确分类这个样本。从几何角度来看，感知机算法实际上是在不断地调整超平面的位置和方向，使得误分类点离超平面更远，从而最终找到一个能够正确分类所有样本的超平面。

感知机学习策略：随机初始化 $\boldsymbol{w}$ 和 b，将 D 中全体的训练样本代入模型找出误分类样本，假设此时误分类样本集合为 $M\subseteq D$，对任意一个误分类样本$(\boldsymbol{x},y)\in M$ 来说，当 $\boldsymbol{w}^T x-b\geq 0$ 时，模型输出值为 $\hat{y}=1$，样本真实标记为 $y=0$；反之，当 $\boldsymbol{w}^T\boldsymbol{x}-b<0$ 时，模型输出值为 $\hat{y}=0$，样本真实标记为 $y=1$。综合两种情形可知，式（5-6）恒成立。

$$(\hat{y}-y)(\boldsymbol{w}^T\boldsymbol{x}-b)\geq 0 \tag{5-6}$$

所以，给定数据集 D，损失函数的定义如式（5-7）所示。

$$L(w,b)=\sum_{x\in M}(\hat{y}-y)(\boldsymbol{w}^T\boldsymbol{x}-b) \tag{5-7}$$

显然，此损失函数 $L(\boldsymbol{w},b)$ 是非负的。如果没有误分类点，损失函数值是 0。而且，误分类点越少，误分类点离超平面越近，损失函数值就越小。

损失函数的求解整个推导过程如下：

具体地，给定数据集 $D=\{(\boldsymbol{x}_1,y_1),(\boldsymbol{x}_2,y_2),\ldots,(\boldsymbol{x}_n,y_n)\}$，其中 $\boldsymbol{x}_i\in R^n$，$y_i\in\{-1,1\}$，求参数 $\boldsymbol{w}, b$ 为使损失函数极小化时的解，损失函数极小化如式（5-8）所示。

$$\min_{\boldsymbol{w},b} L(\boldsymbol{w},b)=\min_{\boldsymbol{w},b}\sum_{\boldsymbol{x}_i\in M}(\hat{y}_i-y_i)(\boldsymbol{w}^T\boldsymbol{x}_i-b) \tag{5-8}$$

其中 $M\subseteq D$ 为误分类样本集合。若将阈值 b 看作一个固定输入为 -1 的“哑结点”，令 $x_{n+1}=-1$，则 $-b=-1\times w_{n+1}=x_{n+1}\times w_{n+1}$。

根据上式，可将要求解的极小化问题进一步简化为式（5-9）所示。

$$\min_{\boldsymbol{w}} L(\boldsymbol{w})=\min_{\boldsymbol{w}}\sum_{\boldsymbol{x}_i\in M}(\hat{y}_i-y_i)\boldsymbol{w}^T\boldsymbol{x}_i \tag{5-9}$$

当误分类样本集合 M 固定时，那么可以求得损失函数 $L(\boldsymbol{w})$ 的梯度如式（5-10）所示。

$$\nabla_{\boldsymbol{w}} L(\boldsymbol{w})=\sum_{\boldsymbol{x}_i\in M}(\hat{y}_i-y_i)\boldsymbol{x}_i \tag{5-10}$$

感知机的学习算法具体采用的是随机梯度下降法，也就是极小化过程中不是一次使所有误分类点的梯度下降，而是一次随机选取一个误分类点使其梯度下降。所以权重 $\boldsymbol{w}$ 的更新公式如式（5-11）所示。

$$\begin{aligned}&\boldsymbol{w}\leftarrow\boldsymbol{w}+\Delta\boldsymbol{w}\\&\Delta\boldsymbol{w}=-\eta(\hat{y}_i-y_i)\boldsymbol{x}_i=\eta(y_i-\hat{y}_i)\boldsymbol{x}_i\end{aligned} \tag{5-11}$$

其中，η 是学习率，它控制了每次更新的步长。

2.1.2 多层感知机的工作原理

下面研究多层感知机的参数学习过程。

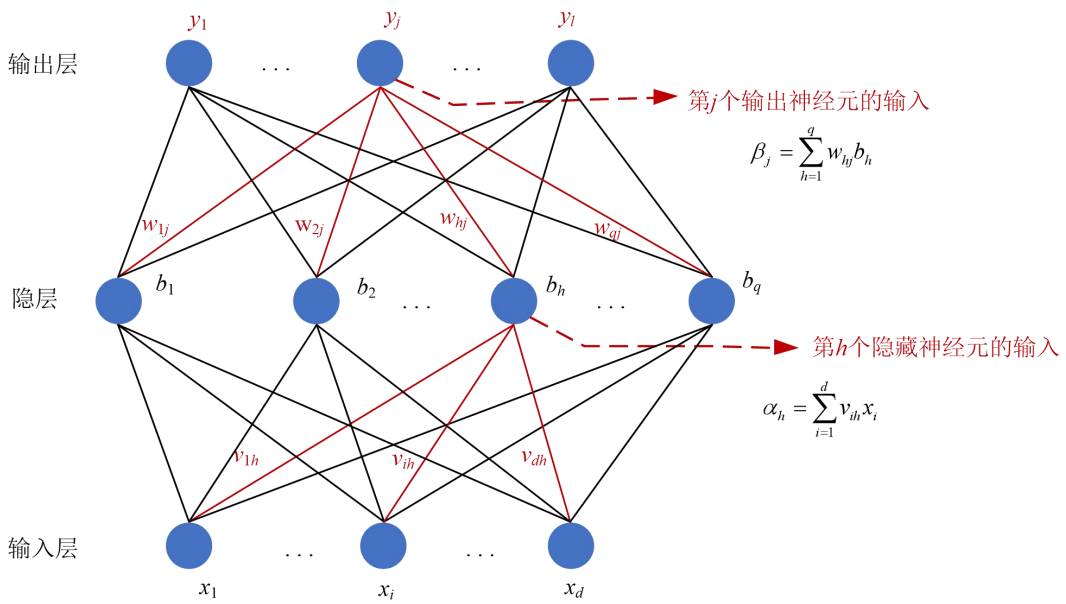

图 5-18 反向传播神经网络及算法中的变量符号

给定训练集 $D=\{(\boldsymbol{x}_1,\boldsymbol{y}_1),(\boldsymbol{x}_2,\boldsymbol{y}_2),\ldots,(\boldsymbol{x}_m,\boldsymbol{y}_m)\}$，$\boldsymbol{x}_i\in R^d$，$\boldsymbol{y}_i\in R^l$，即输入示例由 d 个属性描述，输出 l

维实数向量。为便于讨论，图 5-18 给出了一个拥有 d 个输入神经元，l 个输出神经元，q 个隐层神经元的多层前馈网络结构，其中输出层第 j 个神经元的阈值用 θ_j 表示，隐层第 h 个神经元的阈值用 γ_h 表示。输入层第 i 个神经元与隐层第 h 个神经元之间的连接权重为 v_{ih}，隐层第 h 个神经元与输出层第 j 个神经元之间的连接权重为 w_{hj}，隐层第 h 个神经元接收到的输入记为 $\alpha_h = \sum_{i=1}^{d} v_{ih} x_i$，输出层第 j 个神经元接收到的输入为 $\beta_j = \sum_{h=1}^{q} w_{hj} b_h$，其中 b_h 为隐层第 h 个神经元的输出，假设隐层和输出层都使用 Sigmoid 函数，对训练样本（$\boldsymbol{x}_k, \boldsymbol{y}_k$），假定神经网络的输出 $\hat{\boldsymbol{y}}_k = (\hat{y}_1^k, \hat{y}_2^k, ..., \hat{y}_l^k)$，则式（5-24）成立。

$$\hat{y}_j^k = f(\beta_j - \theta_j) \qquad (5\text{-}24$$

则神经网络在（$\boldsymbol{x}_k, \boldsymbol{y}_k$）上的均方误差如式（5-25）所示。

$$E_k = \frac{1}{2}\sum_{j=1}^{l}(\hat{y}_j^k - y_j^k)^2 \qquad (5\text{-}25)$$

图 5-18 中有$(d+l+1)\times q+l$ 个参数需确定：输入层到隐层为 $d\times q$ 个权值，隐层到输出层为 $q\times l$ 个权值，q 个隐藏层神经元的阈值，l 个输出层神经元的阈值。BP 是一个迭代学习算法，在迭代的每一轮中采用广义的感知机学习规则对参数进行更新估计，任意参数 v 的更新估计式为式（5-26）所示。

$$v \leftarrow v + \Delta v \qquad (5\text{-}26$$

下面以图 5-18 中隐层到输出层的连接权 w_{hj} 为例来推导。

BP 算法是基于梯度下降策略，以目标的负梯度方向对参数进行调整，对式（5-23）的误差 E_k，给定学习率 η，有式（5-27）成立。

$$\Delta w_{hj} = -\eta \frac{\partial E_k}{\partial w_{hj}} \qquad (5\text{-}27$$

注意到 w_{hj} 先影响到第 j 个输出层神经元的输入值 β_j，再影响到其输出值 $\hat{y}_j^k$，然后影响到 E_k，有式（5-28）成立。

$$\frac{\partial E_k}{\partial w_{hj}} = \frac{\partial E_k}{\partial \hat{y}_j^k} \cdot \frac{\partial \hat{y}_j^k}{\partial \beta_j} \cdot \frac{\partial \beta_j}{\partial w_{hj}} \qquad (5\text{-}28)$$

根据 β_j 的定义，显然有式（5-29）成立。

$$\frac{\partial \beta_j}{\partial w_{hj}} = b_h \qquad (5\text{-}29)$$

Sigmoid 函数有一个很好的性质，它的导函数如式（5-30）所示。

$$f'(x) = f(x)(1 - f(x)) \tag{5-30}$$

根据式（5-24）和式（5-25），有式（5-31）成立。

$$\begin{aligned} g_j &= -\frac{\partial E_k}{\partial \hat{y}_j^k} \cdot \frac{\partial \hat{y}_j^k}{\partial \beta_j} \\ &= -(\hat{y}_j^k - y_j^k) \cdot f'(\beta_j - \theta_j) \\ &= -(\hat{y}_j^k - y_j^k) \cdot \hat{y}_j^k (1 - \hat{y}_j^k) \\ &= \hat{y}_j^k (1 - \hat{y}_j^k)(y_j^k - \hat{y}_j^k) \end{aligned} \tag{5-31}$$

将式（5-31）和（5-29）带入（5-28），再带入（5-27），就得到了 BP 算法中关于 w_{hj} 的更新公式，如式（5-32）所示。

$$\Delta w_{hj} = \eta g_j b_h \tag{5-32}$$

类似可得式（5-33）-（5-35）

$$\Delta \theta_j = -\eta g_j \tag{5-33}$$

$$\Delta v_{ih} = \eta e_h x_i \tag{5-34}$$

$$\Delta \gamma_h = -\eta e_h \tag{5-35}$$

式（5-34）和（5-35）中，e_h 的推导过程如式（5-36）所示。

$$\begin{aligned} e_h &= -\frac{\partial E_k}{\partial b_h} \cdot \frac{\partial b_h}{\partial \alpha_h} \\ &= -\sum_{j=1}^{l} \frac{\partial E_k}{\partial \beta_j} \cdot \frac{\partial \beta_j}{\partial b_h} f'(a_h - \gamma_h) \\ &= \sum_{j=1}^{l} w_{hj} g_j f'(a_h - \gamma_h) \\ &= b_h (1 - b_h) \sum_{j=1}^{l} w_{hj} g_j \end{aligned} \tag{5-36}$$

学习率 $\eta \in (0,1)$ 控制着算法每一轮迭代中的更新步长，若太大则容易震荡，太小则收敛速度又会过慢，有时为了做精细调节，可令式（5-32）与（5-33）使用 η_1，式（5-34）与（5-35）使用 η_2，两者未必相等。

三、实验步骤

3.1 数据集

3.2 数据预处理

3.3 利用感知机构建癌症分类模型

3.3.1 代码实现

3.3.2 运行结果

3.4 利用多层感知机构建癌症分类模型

3.4.1 代码实现

3.4.2 运行结果

四、实验对比分析

五、实验总结

六、参考文献