实验要求：

1. 请把实验步骤下所有内容以及实验对比分析和参考文献部分补充完整。介绍数据集的来源以及属性特征的含义；训练集和测试集的划分方式；数据预处理的过程；代码实现给出源代码，运行结果给出运行结果截图并进行分析；实验对比分析，可以用表格汇总三种模型的评价指标，进行对比分析。

2. 报告提交电子版（命名格式：专业+班级+学号+姓名，如：

“机器学习-实验一：软件专硕 221 班 202235xx 张三”

最后提交时，这页内容删除。

大连交通大学

《机器学习》上机实验五

题　　目　利用贝叶斯分类器构建西雅图天气分类模型

学生姓名　　专业班级　软件专硕 221 班

学号　20223561

所在院系

指导教师　殷丽凤

完成日期　2024　年　4 月 9 日

一、实验目的和要求

实验目的：

1. 掌握先验概率、后验概率和贝叶斯定理。
2. 掌握贝叶斯分类器原理。
3. 掌握朴素贝叶斯分类器、半朴素贝叶斯分类器和贝叶斯网络的工作原理。
4. 掌握准确率、精准率、召回率、F1 等分类评价指标。
5. 熟悉 numpy、pandas、matplotlb、scikit-learn 等库实现朴素贝叶斯分类器、半朴素贝叶斯分类器和贝叶斯网络第西雅图天气情况进行预测分类。

实验要求：

1. 理解先验概率、后验概率和贝叶斯定理的概念及其在贝叶斯分类器中的应用。
2. 理解贝叶斯分类器原理。
3. 理解朴素贝叶斯分类器、半朴素贝叶斯分类器和贝叶斯网的工作原理，掌握这些算法的具体实现步骤。
4. 理解准确率、精准率、召回率、F1 等分类评价指标的概念及其在分类器性能评估中的应用。
5. 熟悉使用 numpy、pandas、matplotlib、scikit-learn 等 Python 库进行数据处理、可视化和建模；实现朴素贝叶斯分类器、半朴素贝叶斯分类器和贝叶斯网络，以及相应的训练和预测过程；使用西雅图天气数据集或其他适当的数据集进行分类预测实验，并进行结果分析和解释。
6. 撰写实验报告，包括实验内容和方法、实验步骤、实验对比分析、以及对实验中遇到的问题和解决方法的总结等内容。

二、实验内容与方法

2.1 贝叶斯分类器原理

2.1.1 贝叶斯决策论

最小化错误率的贝叶斯最优分类器为：

$$h^*(\boldsymbol{x}) = \underset{c \in y}{\arg\max}\, P(c \mid \boldsymbol{x}) \tag{7-13}$$

即对于每个样本 $\boldsymbol{x}$，选择其后验概率 $P(c \mid \boldsymbol{x})$ 最大所对应的类标，能使得总体风险函数最小，从而将原问题转化为估计后验概率 $P(c \mid \boldsymbol{x})$。

不难看出，欲使用贝叶斯判定准则来最小化决策风险，首先要获得后验概率 $P(c \mid \boldsymbol{x})$。然而，在现实任务中这通常难以直接获得。从这个角度看，机器学习所要实现的是基于有限的训练样本集尽可能准确地估计出后验概率 $P(c \mid \boldsymbol{x})$。大体来说，一般有两种策略来对后验概率 $P(c \mid \boldsymbol{x})$ 进行估计：

1）判别式模型：直接对 $P(c \mid \boldsymbol{x})$ 进行建模，例如前面所学习的决策树、神经网络和 SVM 都属于判别式模型。

2）生成式模型：通过先对联合分布 $P(\boldsymbol{x}, c)$ 建模，从而进一步求解 $P(c \mid \boldsymbol{x})$。而贝叶斯分类器就属于生成式模型，基于贝叶斯公式对后验概率 $P(c \mid \boldsymbol{x})$ 进行相应变换：

$$P(c \mid \boldsymbol{x}) = \frac{P(c)P(\boldsymbol{x} \mid c)}{P(\boldsymbol{x})} \tag{7-14}$$

估计后验概率 $P(c \mid \boldsymbol{x})$ 就便成为估计类先验概率和类条件概率的问题。

对于给定的样本 $\boldsymbol{x}$，$P(\boldsymbol{x})$与类别无关，$P(c)$称为类先验概率，它就是样本空间中各类样本所占的比例，根据大数定理（当样本足够多时，频率趋于稳定等于其概率），这样当训练样本充足时，$P(c)$可以使用各类出现的频率来代替。$P(\boldsymbol{x}|c)$称为类条件概率，它表达的意思是在类别 c 中出现 $\boldsymbol{x}$ 的概率，它涉及到属性的联合概率问题，若只有一个离散属性还好，但当属性多时采用频率估计起来就十分困难，因此这里一般采用极大似然法进行估计。

2.1.2 极大似然估计

极大似然估计是一种根据数据采集来估计概率分布的经典方法。常用的策略是先假定总体具有某种确定的概率分布，再基于训练样本对概率分布的参数进行估计。运用到类条件概率 $P(\boldsymbol{x} \mid c)$ 中，假定 $P(\boldsymbol{x} \mid c)$ 服从一个参数为 θ 的分布，问题就变为根据已知的训练样本来估计 θ。极大似然法的核心思想就是：估计出的参数使得已知样本出现的概率最大，即使得训练数据的似然最大。

令 D_c 表示训练集 D 中第 c 类样本组成的集合，假设这样的样本是独立同分布的，则参数 θ_c 对于数据集 D_c 的似然是：

$$P(D_c \mid \theta_c) = \prod_{\boldsymbol{x} \in D_c} P(\boldsymbol{x} \mid \theta_c) \tag{7-15}$$

连乘使得求解变得十分复杂且易造成下溢，通常使用对数似然：

$$LL(\theta_c) = \log P(D_c \mid \theta_c) = \log \prod_{\boldsymbol{x} \in D_c} P(\boldsymbol{x} \mid \theta_c) = \sum_{\boldsymbol{x} \in D_c} \log P(\boldsymbol{x} \mid \theta_c) \tag{7-16}$$

θ_c 的极大似然估计 $\hat{\theta}_c$ 为：

$$\hat{\theta}_c = \underset{\theta_c}{\operatorname{argmax}}\, LL(\theta_c) \tag{7-17}$$

所以，贝叶斯分类器的训练过程就是参数估计。

最大似然法估计参数的过程如下：

1）写出似然函数；

2）对似然函数取对数，并整理；

3）求导数，令偏导数为 0，得到似然方程组；

4）解似然方程组，得到所有参数即为所求。

2.2 朴素贝叶斯分类器

朴素贝叶斯分类器（naïve Bayes classifier）采用了“属性条件独立性假设”，即假设对已知的类别，所有的属性相互独立。

后验概率可以写为：

$$P(c \mid \boldsymbol{x}) = \frac{P(c)P(\boldsymbol{x} \mid c)}{P(\boldsymbol{x})} = \frac{P(c)}{P(\boldsymbol{x})} \prod_{i=1}^{d} P(x_i \mid c) \tag{7-19}$$

其中，d 为属性数目，即 $\boldsymbol{x}$ 的维数，x_i 为 $\boldsymbol{x}$ 在第 i 个属性上的取值。这样，为每个样本估计类条件概率变成为每个样本的每个属性估计类条件概率。

由于对于所有类别，$P(\boldsymbol{x})$相同，因此贝叶斯判定准则为：

$$h_{nb}(\boldsymbol{x}) = \underset{c \in y}{\arg\max}\, P(c) \prod_{i=1}^{d} P(x_i \mid c) \tag{7-20}$$

对于离散属性，属性的类条件概率可估计为：

$$P(x_i \mid c) = \frac{|D_{c,x_i}|}{|D_c|} \tag{7-21}$$

对于连续属性，假定 $p(x_i \mid c) \sim N(\mu_{c,i}, \sigma_{c,i}^2)$，其中 $\mu_{c,i}$ 和 $\sigma_{c,i}^2$ 分别是第 c 类样本在第 i 个属性上取值的均值和方差，则有:

$$P(x_i \mid c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}) \tag{7-22}$$

2.3 半朴素贝叶斯分类器

半朴素贝叶斯分类器的基本想法是适当考虑一部分属性间的相互依赖信息，从而既不需进行完全联合概率计算，又不至于彻底忽略了比较强的属性依赖关系。如图 7-6 c“独依赖估计”（One-Dependent Estimator，ODE）是半朴素贝叶斯分类器最常用的策略，即假设每个属性在类别之外最多仅仅依赖于一个其他属性。即：

$$P(c \mid \boldsymbol{x}) \propto P(c) \prod_{i=1}^{d} P(x_i \mid c_i, pa_i) \tag{7-24}$$

其中 pa_i 为属性 x_i 所依赖的属性，称为 x_i 的父属性；此时，对每个属性 x_i，若其父属性 pa_i 已知，则可采用拉普拉斯修正后的类条件概率的方法来估计 $P(x_i \mid c_i, pa_i)$ 概率值。
如何确定每个属性的父属性呢？几种常见的方法有三种，超父独依赖分类器、平均独依赖估计和树增广朴素贝叶斯。

2.4 贝叶斯网络

给定训练集 $D=\{x_1, x_2, \ldots, x_m\}$，贝叶斯网 $B=<G,\Theta>$ 在 D 上的评分函数可写为：

$$s(B \mid D) = f(\theta)|B| - LL(B \mid D) \tag{7-32}$$

其中，$|B|$是贝叶斯网的参数个数；$f(\theta)$ 表示描述每个参数 θ 使用多少个编码位数；而式（7-33）是贝叶斯网络 B 在训练集 D 上的对数似然，m 代表特征个数。

$$LL(B \mid D) = \sum_{i=1}^{m} \log P_B(x_i) \tag{7-33}$$

评分函数可以看成由两个部分构成，第一项 $f(\theta)|B|$ 考虑的是整个贝叶斯网络中用于编码参数的编码位的多少，第二项 $LL(B \mid D)$ 是贝叶斯网络的对数似然。当最小化评分函数时，希望编码位数量越少越好，这基于“最小描述长度”准则，即指希望模型能够描述整个训练集（也就是学习到整个训练集的信息），在这个基础上，模型的复杂程度越低越好，那么这个复杂程度如何用数学语言表示呢？这就是模型中用于编码参数的位数越少越好。这样做的好处：一是模型变得较为简单，在预测时不需要进行大量的计算，二是简单的模型避免了过拟合，泛化性能更好。

三、实验步骤

3.1 数据集

3.2 数据预处理

3.3 利用朴素贝叶斯构建西雅图天气预测分类模型

3.3.1 代码实现

3.3.2 运行结果

3.4 利用半朴素贝叶斯构建西雅图天气预测分类模型

3.4.1 代码实现

3.4.2 运行结果

3.5 利用贝叶斯网构建西雅图天气预测分类模型

3.5.1 代码实现

3.5.2 运行结果

四、实验对比分析

五、实验总结

六、参考文献