**实验要求：**

1. 请把实验步骤下所有内容以及实验对比分析和参考文献部分补充完整。介绍数据集的来源以及属性特征的含义；训练集和测试集的划分方式；数据预处理的过程；代码实现给出源代码，运行结果给出运行结果截图并进行分析；实验对比分析，可以用表格汇总三种模型的评价指标，进行对比分析。

2. 报告提交电子版（命名格式：专业+班级+学号+姓名，如：

“机器学习-实验一：软件专硕 221 班 202235xx 张三”

最后提交时，这页内容删除。

大连交通大学

# 《机器学习》上机实验六

题　　目　利用四种聚类算法进行聚类分析

学生姓名　　专业班级　软件专硕 221 班

学号　20223561

所在院系

指导教师　殷丽凤

完成日期　2024　年　4　月　13　日

# 一、实验目的和要求

实验目的：

1. 理解聚类相关定义：了解聚类的概念和作用，以及聚类在数据分析和机器学习中的应用。

2. 掌握不同种类聚类算法的思想：了解 K-Means、Hierarchical K-means 和 DBSCAN 等不同种类聚类算法的基本原理和思想，以及它们适用的场景。

3. 理解基于划分的 K-Means 聚类算法的工作原理：熟悉 K-Means 算法的工作流程，包括初始化质心、分配样本到最近的质心、更新质心等步骤。

4. 理解基于层次的 Hierarchical K-means 算法的工作原理：了解 Hierarchical K-means 算法的工作原理，包括如何构建层次聚类树、如何划分簇等。

5. 理解基于密度的 DBSCAN 算法的工作原理：熟悉 DBSCAN 算法的核心概念，包括核心对象、邻域、密度直达等概念，以及算法如何划分簇。

6. 熟悉聚类评价指标：了解 DBI（Davies-Bouldin Index）、DI（Dunn Index）、SC（Silhouette Coefficient）、SSE（Sum of Squared Errors）和 SBD（Simplified Bounded Distance）等聚类评价指标的计算方法和含义，以便评估聚类结果的质量。

7. 掌握使用 numpy、pandas、matplotlib、scikit-learn 等库实现聚类算法：能够使用这些库实现 K-Means 聚类算法、Hierarchical K-means 算法和 DBSCAN 算法，并能够对聚类结果进行可视化展示和评价。

实验要求：

1. 理解聚类相关定义：理解聚类的概念、作用以及在数据分析和机器学习中的应用场景。

2. 掌握不同种类聚类算法的思想：了解 K-Means、Hierarchical K-means 和 DBSCAN 等不同聚类算法的原理，包括它们的优缺点和适用场景。

3. 理解基于划分的 K-Means 聚类算法的工作原理：熟悉 K-Means 算法的核心步骤，包括初始化质心、分配样本到最近的质心、更新质心等。

4. 理解基于层次的 Hierarchical K-means 算法的工作原理：了解 Hierarchical K-means 算法如何构建层次聚类树、划分簇等。

5. 理解基于密度的 DBSCAN 算法的工作原理：熟悉 DBSCAN 算法的核心概念，包括核心对象、邻域、密度直达等，以及算法如何划分簇。

6. 熟悉聚类评价指标：了解 DBI、DI、SC、SSE 和 SBD 等聚类评价指标的计算方法和含义，以评估聚类结果的质量。

7. 掌握使用 numpy、pandas、matplotlib、scikit-learn 等库实现聚类算法：能够利用这些库实现 K-Means 聚类、Hierarchical K-means 聚类和 DBSCAN 聚类，并能够对聚类结果进行可视化展示和评价

8. 撰写实验报告，包括实验内容和方法、实验步骤、实验对比分析、以及对实验中遇到的问题和解决方法的总结等内容。

# 二、实验内容与方法

## 2.1K-Means 算法

K-Means 算法是一种常见的基于划分的聚类算法，将一组 $N$ 个样本的特征矩阵 $\boldsymbol{X}$ 划分为 $K$ 个无交集的簇，直观上来看，簇是一组一组聚集在一起的数据，在一个簇中的数据就认为是同一类。簇

就是聚类的结果表现，簇中所有数据的均值通常被称为这个簇的“质心”（centroids）。在一个二维平面中，一簇数据点的质心的横坐标就是这一簇数据点的横坐标的均值，质心的纵坐标就是这一簇数据点的纵坐标的均值。同理可推广至高维空间。

**1.K-Means 算法的步骤**

K-Means 算法是发现给定数据集的 $K$ 个簇的算法。簇个数 $K$ 是用户给定的，每一个簇通过其质心（centroid）来描述。K-Means 算法是一种迭代算法，其主要步骤如下：

1）选择 $K$ 值：首先需要选择要划分的簇的数量 $K$。

2）初始化质心：随机选择 $K$ 个样本作为初始质心。这些初始质心可以是从数据集中随机选择的样本，或者通过其他初始化方法得到的。

3）分配样本：对于每个样本，计算它们与每个质心的距离，然后将样本分配到距离最近质心所在的簇。

4）更新质心：对于每个簇，计算簇中所有样本的平均值，将该平均值作为新的质心。

5）重复迭代：重复步骤 3）和步骤 4），直到质心不再发生显著变化，或达到预定的迭代次数。

K-Means 算法复杂度为 $O(t\times k\times n\times d)$，其中 $t$ 是迭代次数，$k$ 是类数，$n$ 是数据点个数，$d$ 是数据维度。

**2.K-Means 算法的流程图**

根据 K-Means 算法的步骤对应的流程图如图 8-1 所示。

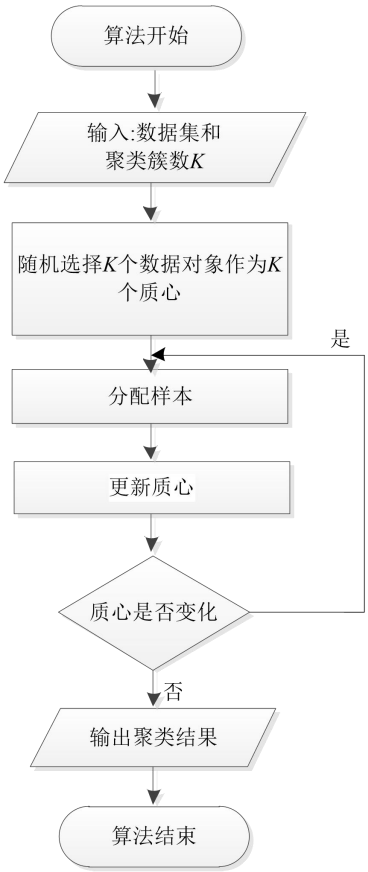


图 8-1 K-Means 算法流程图

## 2.2 K-Means++算法

通常情况下，K-Means 算法在初始质心的选择上比较随机，容易受到初始质心位置的影响，可能导致陷入局部最优解。K-Means++算法是 K-Means 算法的改进版本，它通过一种轮盘法（概率选择法）的方式选择初始的聚类中心，以提高 K-Means 算法的聚类效果。

**1. K-Means++算法的步骤**

以下是 K-Means++算法的具体步骤：

1）初始化第一个聚类中心：随机选择一个样本点作为第一个聚类中心。

2）选择其他聚类中心：对于剩下的每个样本点，计算它与当前已选择的聚类中心的最短距离（即与最近的聚类中心的距离）。选择下一个聚类中心时，需要以概率分布的方式选择，距离较远的点被选中的概率较大。

3）重复选择聚类中心：重复进行步骤 2，直到选择出 $K$ 个聚类中心。

4）执行 K-Means 算法：使用选择出的聚类中心作为初始中心，进行 K-Means 算法的迭代操作，直至收敛。

**2. 轮盘法选择质心**

轮盘法（也称为轮盘赌法或者概率选择法）是一种按照概率分布进行随机选择的方法。在 K-Means++算法中，轮盘法通常用于根据概率分布来选择下一个聚类中心。

具体步骤如下：

1）计算每个样本点到最近聚类中心的距离，并将这些距离转换为概率分布。距离越远的点对应的概率越大。

2）生成一个 0 到 1 之间的随机数 rand_num。

3）遍历计算得到的概率分布，累计概率，直到累计概率大于随机数 rand_num。此时对应的样本点被选为下一个聚类中心。

## 2.3 Hierarchical K-Means 算法

Hierarchical K-Means 算法是“自顶向下”的层次聚类算法，用到了基于划分的聚类算法 K-Means，算法思路如下：

1）首先，把原始数据集放到一个簇 $C$，这个簇形成了层次结构的最顶层；

2）使用 K-Means 算法把簇 $C$ 划分成指定的 $K$ 个子簇 $C_i$，$i = 1, 2, \ldots, K$，形成一个新的层；

3）对于步骤（2）所生成的 $K$ 个簇，递归使用 K-Means 算法划分成更小的子簇，直到每个簇不能再划分（只包含一个数据对象）或者满足设定的终止条件。

## 2.4 DBSCAN 算法

**1.DBSCAN 算法原理**

DBSCAN 通过查看每个对象的 *Eps* 邻域来搜索数据集的高数据密度区域，如果一个数据对象的 *Eps* 邻域的对象数量超过 *MinPts* 密度阈值，则该数据对象作为新形成的集群的核心对象。DBSCAN 反复查找这些核心对象可以直接密度可达的对象，并将这些数据对象标记为一个类。当没有新的数据对象可以添加到任何聚类中时，没有类别的数据对象被标记为噪声点，聚类过程结束。

**2.DBSCAN 算法步骤**

DBSCAN 算法的步骤如下：

Step1：指定适当的 *Eps* 和 *MinPts*。

Step2：任意选择一个点，然后找到所有到该点的距离小于或等于 *Eps* 的点。如果距离起点 *Eps* 距离内的数据点数量小于 *MinPts*，则将该点标记为噪声。如果 *Eps* 距离内的数据点数量大于 *MinPts*，则将该点标记为核心点并分配一个新的群集标签。

Step3：访问该核心点的所有密度可达对象(*Eps* 距离内）。如果没有为它们分配集群，则会为它们分配刚刚创建的新集群标签。如果它们是核心点，那么依次访问它们直接密度可达的对象，依此类推。簇不断增长，直到簇的 *Eps* 距离内不再有核心点为止。

Step4：选择另一个没有被访问过的点，重复相同的过程，直到所有核心点都被访问过。

Step5：输出聚类结果。

**3.DBSCAN 算法流程**

（1）建立相邻点集合

对于 DBSCAN 算法的流程而言，第一步是要建立相邻点集合。在此步骤中，需要确定以每个点为中心、以特定的半径进行距离计算，得出与该点的距离不超过给定半径的所有点组成的集合，也就是该点的相邻点集合。通过这一步骤，就可以为接下来的密度判断和簇扩展做好准备。接下来，DBSCAN 算法会进行密度判断，即判断每个点的相邻点集合的大小是否满足密度要求。若某一点的相邻点集合大小达到了指定的阈值，则该点被判定为核心点；若某一点的相邻点集合大小不足指定阈值，但其仍然与某个核心点相连，则该点被判定为边界点；若某一点不能与任何核心点相连，则该点被判定为噪音点。

在判定完密度之后，DBSCAN 算法会对核心点建立所属簇，即对于每个核心点，将该点的所有直接密度可达点（包括该核心点本身）加入其所在簇中。对于边界点和噪音点，则不属于任何一个簇。

最后，DBSCAN 算法会对所有簇进行扩展，即将所有与某一簇中点直接密度可达的点（不包括该簇中已有的点）加入该簇中，依次扩展直到无法继续扩展为止。经过簇扩展之后，一个完整的 DBSCAN 算法的聚类过程就完成了。

（2）标记核心点、边界点、噪声点

在 DBSCAN 算法流程中，需要标记核心点、边界点和噪声点。核心点是指在半径 *Eps* 内包含至少 *MinPts* 个点的点，边界点是指至少有一个邻居在半径 *Eps* 内，但是邻居数量不足 *MinPts* 的点，噪声点是指没有足够邻居的点。通过标记这些点，可以对聚类结果进行更加准确的划分。对于每个核心点，其邻居点都必定属于同一簇中。通过从某个核心点出发，向邻居点的邻居点扩张，可以递归地搜索与该核心点相连的所有点，从而得到一个聚类簇。一旦没有邻居点，或邻居点均为噪声点，则该聚类簇搜索结束。对于边界点，其只能被分配到与之距离最近的核心点所属的簇中。最终，未被标记的噪声点则被视为离群点，不属于任何聚类簇。在具体实现时，可以通过计算数据点间的距离矩阵，找到所有 *Eps* 邻域内的点，并根据 *MinPts* 来确定是否为核心点或边界点。接着，根据构建的连通簇，不断扩张簇的大小，并反复寻找新的核心点，直到所有点均被标记为核心点、边界点或噪声点。

（3）建立聚类

首先，DBSCAN 算法需要确定两个参数，一个是 *Eps*，表示邻域半径；另一个是 *MinPts*，表示邻域内最少的点数。接着，从任意一个未标记的点开始，找出所有密度可达的点，并给予他们一个标记，将它们构成一个聚类。如果一个密度可达的点也有足够的邻居，则再将它们构成一个新的聚类，并且在以上过程中不断循环，直到所有的点都被聚类为止。在构建聚类的过程中，需要利用邻域查询和密度可达性的概念。即首先需要找到每个点的$\varepsilon$邻域，即以该点为圆心，以 *Eps* 为半径的圆内的所有点。然后对于任意一个未被标记的点 $p$，以 $p$ 为圆心，以 *Eps* 为半径的圆内如果包含了至少 *MinPts* 个点，则将其标记为核心点，并遍历其 *Eps* 邻域，将其中未被标记的点标记为该点的直接密度可达点。一次遍历结束后，该聚类中所有已知密度可达点的邻域内未被标记的点也会被标记为

该聚类的直接密度可达点，并不断重复以上过程，直到该聚类中不存在新的直接密度可达点为止。若该点不是核心点，且不属于任何一个聚类，则将其标记为噪声点。最后遍历所有未被标记的点，重新寻找密度可达点，直到所有点被标记为止。

# 三、实验步骤

## 3.1 利用 K-Means 和 K-Means++完成亚马逊产品评论信息聚类

### 3.1.1 数据集

### 3.1.2 数据预处理

### 3.1.3 代码实现

### 3.1.4 运行结果

## 3.2 利用 Hierarchical K-Means 算法完成用户行为数据聚类

### 3.2.1 数据集

### 3.2.2 数据预处理

### 3.2.3 代码实现

### 3.2.4 运行结果

## 3.3 利用 DBSCAN 算法完成芝加哥公园区水和天气信息的聚类

### 3.3.1 数据集

### 3.3.2 数据预处理

### 3.3.3 代码实现

### 3.3.4 运行结果

## 四、实验对比分析

## 五、实验总结

## 六、参考文献