实验要求：

1. 请把实验步骤下所有内容以及实验对比分析和参考文献部分补充完整。介绍数据集的来源以及属性特征的含义；训练集和测试集的划分方式；数据预处理的过程；代码实现给出源代码，运行结果给出运行结果截图并进行分析；实验对比分析，可以用表格汇总三种模型的评价指标，进行对比分析。

2. 报告提交电子版（命名格式：专业+班级+学号+姓名，如：

“机器学习-实验一：软件专硕 221 班 202235xx 张三”

最后提交时，这页内容删除。

大连交通大学

《机器学习》上机实验四

题　　目　利用支持向量机构建泰坦尼克号分类模型

学生姓名　　专业班级　软件专硕 221 班

学号　20223561

所在院系

指导教师　殷丽凤

完成日期　2024　年　3　月　29　日

一、实验目的和要求

实验目的：

1. 掌握硬间隔 SVM 和软间隔 SVM 的工作原理。
2. 掌握硬间隔 SVM 和软间隔 SVM 的参数推导过程以及核函数。
3. 掌握准确率、精准率、召回率、F1 等分类评价指标。
4. 熟悉利用 Python 语言人工实现硬间隔 SVM 和软间隔 SVM 算法并对泰坦尼克号生存情况进行预测分类；或熟悉利用 numpy、pandas、matplotlb、scikit-learn 等库实现硬间隔 SVM 和软间隔 SVM 算法并对泰坦尼克号生存情况进行预测分类。

实验要求：

1. 掌握硬间隔 SVM 和软间隔 SVM 的工作原理以及核函数。
2. 掌握硬间隔 SVM 和软间隔 SVM 的参数推导过程，包括目标函数的定义和优化方法。
3. 理解准确率、精确率、召回率、F1 等分类评价指标的含义和计算方法。
4. 熟悉使用 Python 语言实现硬间隔 SVM 和软间隔 SVM 算法的基本步骤（或者利用库进行实现），完成对泰坦尼克号生存情况进行预测分类。实验中包括数据的预处理、模型的构建、训练和评估。
5. 撰写实验报告，包括实验内容和方法、实验步骤、实验对比分析、以及对实验中遇到的问题和解决方法的总结等内容。

二、实验内容与方法

2.1 硬间隔支持向量机

假设超平面 $\boldsymbol{w}^T\boldsymbol{x}+b=0$ 能将训练样本正确分类，取 a=1，对于 $(\boldsymbol{x}_i, y_i)\in D$，则有：

$$\begin{cases} \boldsymbol{w}^T\boldsymbol{x}_i+b\geq +1, & y=+1 \\ \boldsymbol{w}^T\boldsymbol{x}_i+b\leq -1, & y=-1 \end{cases} \tag{6-10}$$

距离超平面最近的这几个训练样本点使得上述不等式中等号成立，这几个样本点被称为支持向量，两个异类支持向量到超平面的距离之和为 $\frac{2}{\|\boldsymbol{w}\|}$。

因此，最大化间隔问题就是求解一个凸二次规划问题：

$$\max_{\boldsymbol{w},b}\frac{2}{\|\boldsymbol{w}\|} \quad \text{s.t. } y_i(\boldsymbol{w}^T\boldsymbol{x}_i+b)\geq 1,\ i=1,2,...,m. \tag{6-11}$$

显然，为了最大化间隔，仅需要最大化 $\|\boldsymbol{w}\|^{-1}$，这等价于最小化 $\|\boldsymbol{w}\|^2$，于是上式可写为:

$$\min_{\boldsymbol{w},b}\frac{1}{2}\|\boldsymbol{w}\|^2 \quad \text{s.t. } y_i(\boldsymbol{w}^T\boldsymbol{x}_i+b)\geq 1,\ i=1,2,...,m. \tag{6-12}$$

式（6-12）就是硬间隔支持向量机的基本模型。

对式（6-12）中的每条约束添加拉格朗日乘子 $\alpha_i \geq 0$，则该问题的拉格朗日函数可写为式（6-15）。

$$
\begin{aligned}
L(\boldsymbol{w},b,\boldsymbol{\alpha}) &= \frac{1}{2}\|\boldsymbol{w}\|^2 + \sum_{i=1}^{m}\alpha_i(1-y_i(\boldsymbol{w}^T\boldsymbol{x}_i+b)) \\
&= \frac{1}{2}\|\boldsymbol{w}\|^2 + \sum_{i=1}^{m}\alpha_i - \sum_{i=1}^{m}\alpha_i y_i \boldsymbol{w}^T\boldsymbol{x}_i - b\sum_{i=1}^{m}\alpha_i y_i
\end{aligned}
\tag{6-15}
$$

其中 $\boldsymbol{\alpha}=(\alpha_1;\alpha_2;...;\alpha_m)$。令 $L(\boldsymbol{w},b,\boldsymbol{\alpha})$ 对 $\boldsymbol{w}$ 和 b 的偏导为零可得式（6-16）和（6-17）。

$$
\boldsymbol{w} = \sum_{i=1}^{m}\alpha_i y_i \boldsymbol{x}_i \tag{6-16}
$$

$$
0 = \sum_{i=1}^{m}\alpha_i y_i \tag{6-17}
$$

将式（6-16）和（6-17）带入（6-15），即可将 $L(\boldsymbol{w},b,\boldsymbol{\alpha})$ 中的 $\boldsymbol{w}$ 和 b 消去。

$$
\begin{aligned}
L(\boldsymbol{w},b,\boldsymbol{\alpha}) &= \frac{1}{2}\|\boldsymbol{w}\|^2 - \sum_{i=1}^{m}\alpha_i(y_i(\boldsymbol{w}^T\boldsymbol{x}_i+b)-1) \\
&= \frac{1}{2}\boldsymbol{w}^T\boldsymbol{w} - \boldsymbol{w}^T\sum_{i=1}^{m}\alpha_i y_i \boldsymbol{x}_i - b\sum_{i=1}^{m}\alpha_i y_i + \sum_{i=1}^{m}\alpha_i \\
&= \sum_{i=1}^{m}\alpha_i - \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \boldsymbol{x}_i^T\boldsymbol{x}_j
\end{aligned}
\tag{6-18}
$$

上一步骤完成了 $\min\limits_{\boldsymbol{w},b} L(\boldsymbol{w},b,\boldsymbol{a})$，即损失函数取最小值时对应的 $\boldsymbol{w}$ 和 b 的值。下面进行第二步求解，即求 $\boldsymbol{\alpha}$ 的极大值：

$$
\begin{aligned}
&\max_{\boldsymbol{\alpha}} L(\boldsymbol{w},b,\boldsymbol{\alpha}) = \sum_{i=1}^{m}\alpha_i - \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \boldsymbol{x}_i^T\boldsymbol{x}_j \\
&s.t. \sum_{i=1}^{m}\alpha_i y_i = 0, \\
&\quad \alpha_i \geq 0 \quad i=1,2,...,m
\end{aligned}
\tag{6-19}
$$

式（6-19）可以转化为求极小值：

$$
\begin{aligned}
&\min_{\boldsymbol{\alpha}} L(\boldsymbol{w},b,\boldsymbol{\alpha}) = \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \boldsymbol{x}_i^T\boldsymbol{x}_j - \sum_{i=1}^{m}\alpha_i \\
&s.t. \sum_{i=1}^{m}\alpha_i y_i = 0, \\
&\quad \alpha_i \geq 0 \quad i=1,2,...,m
\end{aligned}
\tag{6-20}
$$

这是一个不等式约束下的二次函数极值问题，存在唯一解。根据 KKT 条件，解中将只有一部分

（通常是很小的一部分）不为零，这些不为 0 的解所对应的样本就是支持向量。

假设α^*是上面凸二次规划问题的最优解，则$\alpha^* \neq 0$。假设满足$\alpha^* > 0$，按下面方式计算出的解为原问题的唯一最优解：

$$\begin{aligned} \boldsymbol{w}^* &= \sum_{i=1}^{n} \alpha_i^* y_i \boldsymbol{x}_i \\ b^* &= y_i - \sum_{i=1}^{m} \alpha^* y_i \boldsymbol{x}_i^T \boldsymbol{x}_i \end{aligned} \tag{6-21}$$

2.2 核函数

令$\varphi(\boldsymbol{x})$表示将$\boldsymbol{x}$映射后的特征向量，于是，在特征空间中划分超平面所对应的模型可表示为

$$f(\boldsymbol{x}) = \boldsymbol{w}^T \varphi(\boldsymbol{x}) + b \tag{6-22}$$

其中，$\boldsymbol{w}$，b 是模型参数，类似式（6-12），有

$$\min_{\boldsymbol{w},b} \frac{1}{2}\|\boldsymbol{w}\|^2 \quad \text{s.t.} \;\; y_i(\boldsymbol{w}^T \varphi(\boldsymbol{x}_i) + b) \geq 1, \;\; i = 1, 2, \ldots, m. \tag{6-23}$$

其对偶问题是

$$\begin{aligned} &\max_{\boldsymbol{\alpha}} L(\boldsymbol{w}, b, \boldsymbol{\alpha}) = \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \varphi(\boldsymbol{x}_i)^T \varphi(\boldsymbol{x}_j) \\ &s.t. \sum_{i=1}^{m} \alpha_i y_i = 0, \\ &\quad \alpha_i \geq 0 \;\; i = 1, 2, \ldots, m \end{aligned} \tag{6-24}$$

求解式（6-24）涉及到计算$\varphi(\boldsymbol{x}_i)^T \varphi(\boldsymbol{x}_j)$，这是样本$\boldsymbol{x}_i$与$\boldsymbol{x}_j$映射到特征空间之后的内积。由于特征空间维数可能很高，甚至可能是无穷维，因此直接计算$\varphi(\boldsymbol{x}_i)^T \varphi(\boldsymbol{x}_j)$通常是困难的。为了避开这个障碍，可以设想这样一个函数：

$$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \left\langle \varphi(\boldsymbol{x}_i), \varphi(\boldsymbol{x}_j) \right\rangle = \varphi(\boldsymbol{x}_i)^T \varphi(\boldsymbol{x}_j) \tag{6-25}$$

即$\boldsymbol{x}_i$与$\boldsymbol{x}_j$在特征空间的内积等于他们在原始样本空间中通过函数$\kappa(\cdot,\cdot)$计算的结果。有了这样的函数，就不必直接去计算高维甚至无穷维特征空间中的内积，于是式（6-24）可重写为：

$$
\begin{aligned}
&\max_{\boldsymbol{\alpha}} L(\boldsymbol{w}, b, \boldsymbol{\alpha}) = \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) \\
&s.t. \sum_{i=1}^{m} \alpha_i y_i = 0, \\
&\quad \alpha_i \geq 0 \quad i=1, 2, \ldots, m
\end{aligned}
\tag{6-26}
$$

求解后即可得到：

$$
\begin{aligned}
f(\boldsymbol{x}) &= \boldsymbol{w}^T \varphi(\boldsymbol{x}) + b \\
&= \sum_{i=1}^{m} \alpha_i y_i \varphi(\boldsymbol{x}_i)^T \varphi(\boldsymbol{x}) + b \\
&= \sum_{i=1}^{m} \alpha_i y_i \kappa(\boldsymbol{x}, \boldsymbol{x}_i) + b
\end{aligned}
\tag{6-27}
$$

这里的函数 $\kappa(\cdot,\cdot)$ 就是“核函数”，式（6-27）显示出模型最优解可通过训练核函数展开，这一展开式亦称“支持向量展式”。

2.3 软间隔支持向量机

软间隔支持向量机利用松弛变量允许一些点到分类平面的距离不满足原先的要求。具体约束条件中增加一个松弛项参数 $\varepsilon_i \geq 0$，变成：

$$
y_i(w^T x_i + b) \geq 1 - \varepsilon_i \quad i = 1, 2, \ldots, m \tag{6-32}
$$

显然当 $\varepsilon_i \geq 0$ 足够大时，训练点就可以满足以上条件。虽然得到的分类间隔越大越好。但需要避免 ε_i 取太大的值。所以在目标函数中加入惩罚项 C，得到下面的优化问题:

$$
\begin{aligned}
&\min_{w,b} \frac{1}{2} \| w \|^2 + C \sum_{i=1}^{m} \varepsilon_i \\
&s.t. \ y_i(w^T x_i + b) \geq 1 - \varepsilon_i \quad i = 1, 2, \ldots, m \\
&\quad \varepsilon_i \geq 0 \quad i = 1, 2, \ldots, m
\end{aligned}
\tag{6-33}
$$

其中，$\varepsilon \in R^n$，C 是一个惩罚参数。目标函数意味着既要最小化 $\| w \|^2$（即最大间隔化），又要最小化 $\sum_{i=1}^{m} \varepsilon_i$ (即约束条件的 $y_i(w^T x_i + b) \geq 1$ 的破坏程度)，参数 C 体现了两者总体的一个权衡。C 趋近于很大时：意味着分类严格不能有错误；C 很大，还想让结果比较小，只能是松弛因子很小很小，几乎没有。C 趋近于很小时：意味着可以有更大的错误容忍；松弛因子稍微大一点也可以，不影响整体小。C 是需要指定的一个参数。

求解这一优化问题的方法与求解线性问题最优分类面时所用的方法几乎相同，都是转换为一个

二次函数极值问题，只是在凸二次规划中条件变为：$0 \le \alpha_i \le C,\ i = 1,2,...,m$。

定义拉格朗日函数为：

$$L(w,b,\alpha,\varepsilon,\beta) = \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m}\varepsilon_i + \sum_{i=1}^{m}\alpha_i[1-\varepsilon_i - y_i(w^T x_i + b)] - \sum_{i=1}^{m}\beta_i\varepsilon_i \qquad (6\text{-}34)$$

其中 $\alpha_i \ge 0,\ \beta_i \ge 0$ 是拉格朗日乘子。

令 $L(w,b,\alpha,\varepsilon,\beta)$ 对 w,b,ε 求偏导为 0 可得:

$$\begin{aligned}
&\frac{\partial L}{\partial w} = 0 \Rightarrow w = \sum_{i=1}^{m}\alpha_i y_i x_i \\
&\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^{m}\alpha_i y_i = 0 \\
&\frac{\partial L}{\partial \varepsilon} = 0 \Rightarrow C = \alpha_i + \beta_i
\end{aligned} \qquad (6\text{-}35$$

带入拉格朗日函数，可以消除 w，b，再消去 β_i 得到对偶问题：

$$\begin{aligned}
L(w,b,\alpha,\varepsilon,\beta) &= \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m}\varepsilon_i + \sum_{i=1}^{m}\alpha_i[1-\varepsilon_i - y_i(w^T x_i + b)] - \sum_{i=1}^{m}\beta_i\varepsilon_i \\
&= \frac{1}{2}\|w\|^2 + \sum_{i=1}^{m}\alpha_i[1-y_i(w^T x_i + b)] + C\sum_{i=1}^{m}\varepsilon_i - \sum_{i=1}^{m}\alpha_i\varepsilon_i - \sum_{i=1}^{m}\beta_i\varepsilon_i \\
&= \frac{1}{2}w^T w + \sum_{i=1}^{m}\alpha_i - \sum_{i=1}^{m}\alpha_i y_i w^T x_i - \sum_{i=1}^{m}\alpha_i y_i b + C\sum_{i=1}^{m}\varepsilon_i - \sum_{i=1}^{m}\alpha_i\varepsilon_i - \sum_{i=1}^{m}\beta_i\varepsilon_i \\
&= \frac{1}{2}w^T\sum_{i=1}^{m}\alpha_i y_i x_i - w^T\sum_{i=1}^{m}\alpha_i y_i x_i + \sum_{i=1}^{m}\alpha_i - b\sum_{i=1}^{m}\alpha_i y_i + C\sum_{i=1}^{m}\varepsilon_i - \sum_{i=1}^{m}\alpha_i\varepsilon_i - \sum_{i=1}^{m}\beta_i\varepsilon_i \\
&= -\frac{1}{2}\sum_{i=1}^{m}\alpha_i y_i x_i^T\sum_{i=1}^{m}\alpha_i y_i x_i + \sum_{i=1}^{m}\alpha_i + C\sum_{i=1}^{m}\varepsilon_i - \sum_{i=1}^{m}\alpha_i\varepsilon_i - \sum_{i=1}^{m}\beta_i\varepsilon_i \\
&= -\frac{1}{2}\sum_{i=1}^{m}\alpha_i y_i x_i^T\sum_{i=1}^{m}\alpha_i y_i x_i + \sum_{i=1}^{m}\alpha_i + \sum_{i=1}^{m}(C-\alpha_i-\beta_i)\varepsilon_i \\
&= -\frac{1}{2}\sum_{i=1}^{m}\alpha_i y_i x_i^T\sum_{i=1}^{m}\alpha_i y_i x_i + \sum_{i=1}^{m}\alpha_i \\
&= -\frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j x_i^T x_j + \sum_{i=1}^{m}\alpha_i
\end{aligned}$$

最终转化为的对偶问题为：

$$\begin{aligned}
&\max_{\alpha}\sum_{i=1}^{m}\alpha_i - \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j x_i^T x_j \\
&\text{s.t. } \sum_{i=1}^{m}a_i y_i = 0 \\
&0<\alpha_i<C,\ i=1,2,\dots,m
\end{aligned} \qquad (6\text{-}36)$$

假设α_i^*是上面凸二次规划问题的最优解，则$\alpha_i^* \neq 0$。假设满足$\alpha_i^* > 0$，按下面方式计算出的解为原问题的唯一最优解：

$$w^* = \sum_{i=1}^{m} \alpha_i^* y_i x_i \tag{6-37}$$

在 KKT 条件下希望带入一个支持向量的值来求出 *b**，但是求解 *b* 的值需要*ε*的帮助，而想要求出*ε*的值又需要 *b**的帮助，这种情况下就形成了死锁，什么值都求不出来。恰好有另外一个条件的支撑向量（a≤C 的情况下，称之为自由支持向量），这种支持向量的ε值为 0。这样可以利用自由支持向量来求出 *b**的值。

- 当$0 < \alpha^* < C$时，这时ε的值为 0，可以通过下式进行计算

$$b^* = y_i - \sum_{i=1}^{m} \alpha_i^* y_i x_i^T x_i \tag{6-38}$$

- 当$\alpha^* = 0$：不是支持向量机，无法计算。

- 当$\alpha^* = C$：这个时候$b^* = y_i - \sum_{i=1}^{m} \alpha_i^* y_i x_i^T x_i$ -ε_i，求解 *b**需要 ε，产生了死锁。

三、实验步骤

3.1 数据集

3.2 数据预处理

3.3 利用硬间隔 SVM 构建泰坦尼克号预测分类模型

3.3.1 代码实现

3.3.2 运行结果

3.4 利用软间隔 SVM 构建泰坦尼克号预测分类模型

3.4.1 代码实现

3.4.2 运行结果

四、实验对比分析

五、实验总结

六、参考文献